

## Tarea 03 - Reconocimiento de patrones

### Giovanni Gamaliel López Padilla

## Problema 1

Usemos la distancia de Kullback-Leibler para T-SNE. En el caso discreto, la definición de la distancia de Kullback-Leibler es:

$$d(P^1, P^2) = \sum_i P_i^1 \log \left( \frac{P_i^1}{P_i^2} \right)$$

- Calcula  $d(P^1, P^2)$  si  $P^1 \sim \text{Bern}(\theta_1)$  y  $P^2 \sim \text{Bern}(\theta_2)$ .
- Grafica  $d(P^1, P^2)$  como función de  $\theta_2$  con  $\theta_1$  fija, y verifica que efectivamente mide de alguna manera la disimilitud entre  $P^1$  y  $P^2$ .

Se tiene que

$$P(\theta) = \theta^x (1 - \theta)^{1-x}$$

Calculando  $\log \left( \frac{P_i^1}{P_i^2} \right)$ , se obtiene que:

$$\begin{aligned} \log \left( \frac{P_i^1}{P_i^2} \right) &= \log \left( \frac{\theta_1^x (1 - \theta_1)^{1-x}}{\theta_2^x (1 - \theta_2)^{1-x}} \right) \\ &= \log (\theta_1^x (1 - \theta_1)^{1-x}) - \log (\theta_2^x (1 - \theta_2)^{1-x}) \\ &= x \log(\theta_1) + (1 - x) \log(1 - \theta_1) - x \log(\theta_2) - (1 - x) \log(1 - \theta_2) \\ &= x (\log(\theta_1) - \log(\theta_2)) + (1 - x) (\log(1 - \theta_1) - \log(1 - \theta_2)) \end{aligned}$$

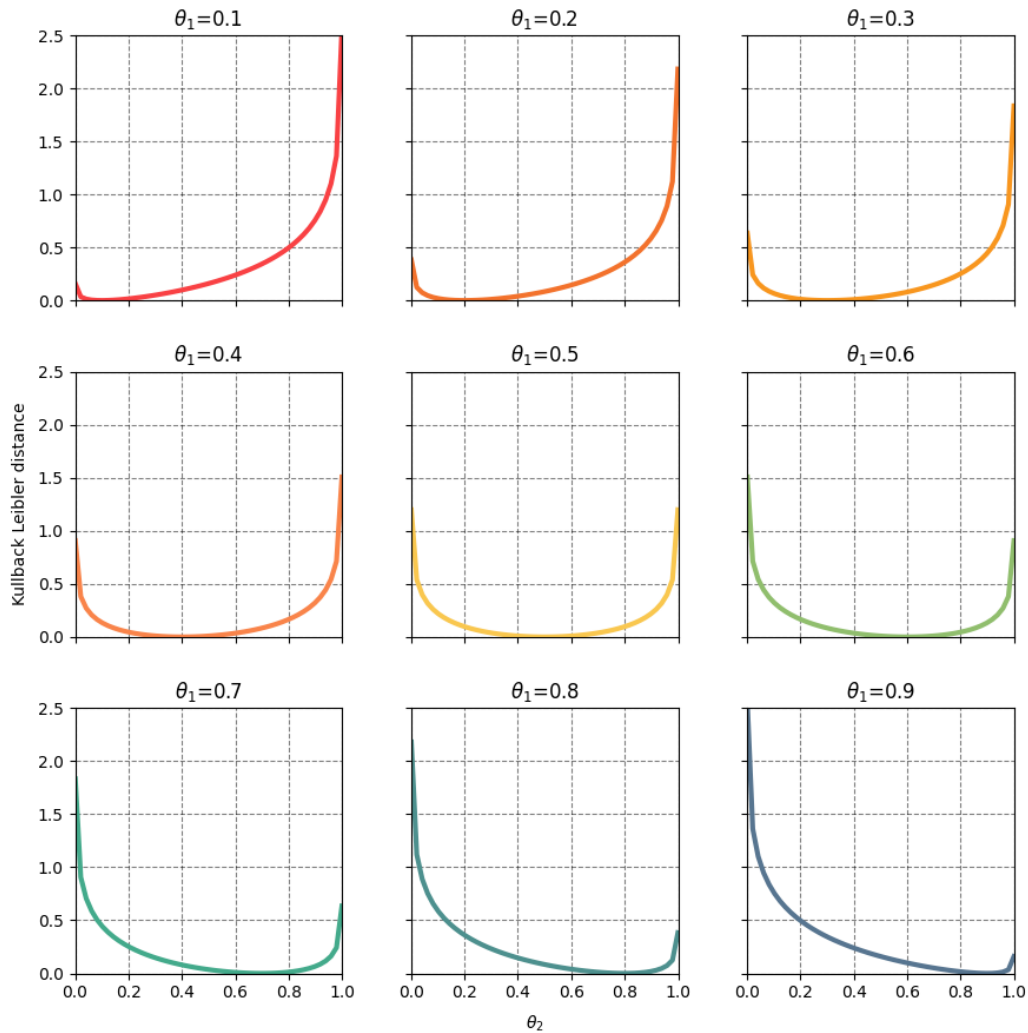
Entonces, la distancia de Kullback-Leibler para dos distribuciones de Bernoulli es la siguiente:

$$\begin{aligned} d(P^1, P^2) &= \sum_{i=0}^1 \theta_1^i (1 - \theta_1)^{1-i} [i (\log(\theta_1) - \log(\theta_2)) + (1 - i) (\log(1 - \theta_1) - \log(1 - \theta_2))] \\ d(P^1, P^2) &= (1 - \theta_1) (\log(1 - \theta_1) - \log(1 - \theta_2)) + \theta_1 (\log(\theta_1) - \log(\theta_2)) \end{aligned}$$

Por lo tanto, la distancia de Kullback-Leibler para dos distribuciones de Bernoulli se puede calcular como en la ecuación 1.

$$d(P^1, P^2) = (1 - \theta_1) (\log(1 - \theta_1) - \log(1 - \theta_2)) + \theta_1 (\log(\theta_1) - \log(\theta_2)) \quad (1)$$


En la figura se visualiza la ecuación 1 para diferentes valores de  $\theta_1$ . En esta se ve que la función alcanza un valor mínimo cuando  $\theta_1$  y  $\theta_2$  son muy semejantes. Por otro lado esta función tiende a infinito cuando los valores tienen una diferencia mayor.



**Figura 1:** Resultados para diferentes valores de  $\theta_1$  en la ecuación 1.

## Problema 02

Ordena las siguientes distribuciones en base de su entropía de Shannon (de menor a mayor). Motiva tu respuesta.



(a) Distribución 1

(b) Distribución 2

(c) Distribución 3

(d) Distribución 4

**Figura 2:** Diferentes distribuciones.

En la tabla 1 se encuentran los alores de las distribuciones de la figura 2.

Distribución	1	2	3	4	5
1	0.20	0.20	0.20	0.20	0.20
2	0.25	0.25	0	0.25	0.25
3	0.34	0.34	0.16	0.16	0
4	0.34	0.16	0	0.16	0.34

**Tabla 1:** Valores de las distribuciones mostradas en la figura 2

Basandonos en los datos, se puede decir que la distribución con mayor entropía es la distribución 1. Esto debido a que todos sus valores contiene la misma probabilidad. Otra afirmación que se puede realizar es que las distribuciones 3 y 4 tienen la misma entropía debido a que tienen una semejanza en su distribución de probabilidades. El cambio es que probabilidad esta asociada a cada valor. Con la información de la tabla 1 se puede calcular la entropía de Shannon para comprobar lo antes dicho. Los resultados se muestran en la tabla 2.

Distribución	1	2	3	4	5	Entropía
1	0.20	0.20	0.20	0.20	0.20	0.6989
2	0.25	0.25	0	0.25	0.25	0.6026
3	0.34	0.34	0.16	0.16	0	0.5732
4	0.34	0.16	0	0.16	0.34	0.5732

**Tabla 2:** Valores de las distribuciones mostradas en la figura 2 con sus respectivos valores de entropía.

Con esto podemos afirmar que el orden de menor a mayor entropía es distribución 3 y 4, después la distribución 2 y por último la distribución 1.

## Problema 03

Muestra que el incremento  $I_{ij}$  en la suma de los errores al cuadrado, sum of squared errors (SSE), del método de mínima varianza de Ward (Ward's minimum variance method), i.e.,

$$\begin{aligned}
 I_{ij} &= SSE_{ij} - (SSE_i + SSE_j) \\
 SSE_i &= \sum_{x \in C_i} \|x_i - \mu_i\|^2 \\
 SSE_j &= \sum_{x \in C_j} \|x_j - \mu_j\|^2 \\
 SSE_{ij} &= \sum_{x \in C_{ij}} \|x_{ij} - \mu_{ij}\|^2
 \end{aligned}$$

donde  $\mu_i$ ,  $\mu_j$  y  $\mu_{ij}$  son los centroides de los clusters  $C_i$ ,  $C_j$  y  $C_i \cup C_j$  respectivamente, se puede escribir como sigue.

$$I_{ij} = \frac{|C_i||C_j|}{|C_i| + |C_j|} \|\mu_i - \mu_j\|^2$$

donde  $|C_i|$  y  $|C_j|$  representan la cardinalidad de los clusters  $C_i$  y  $C_j$  respectivamente.

Calculando  $SSE_{ij}$  se obtiene lo siguiente:

$$\begin{aligned} SSE_{ij} &= \sum_{i \in C_{ij}} \|x_i - \mu_{ij}\|^2 \\ &= \sum_{i \in C_i} \|x_i - \mu_{ij}\|^2 + \sum_{i \in C_j} \|x_i - \mu_{ij}\|^2 \end{aligned}$$

Calculando  $\sum_{i \in C_i} \|x_i - \mu_{ij}\|^2$  se obtiene lo siguiente:

$$\begin{aligned} \sum_{i \in C_i} \|x_i - \mu_{ij}\|^2 &= \sum_{i \in C_i} \left\| x_i - \left( \mu_i - \frac{|C_j|}{|C_i| + |C_j|} (\mu_i - \mu_j) \right) \right\|^2 \\ &= \sum_{i \in C_i} \left\| (x_i - \mu_i) + \frac{|C_j|}{|C_i| + |C_j|} (\mu_i - \mu_j) \right\|^2 \\ &= \sum_{i \in C_i} \|x_i - \mu_i\|^2 + 2 \sum_{i \in C_i} (x_i - \mu_i) \left( \frac{|C_j|}{|C_i| + |C_j|} \right) (\mu_i - \mu_j) + \sum_{i \in C_i} \left( \frac{|C_j|}{|C_i| + |C_j|} \right) \|\mu_i - \mu_j\|^2 \\ &= \sum_{i \in C_i} \|x_i - \mu_i\|^2 + |C_i| \left( \frac{|C_j|^2}{(|C_i| + |C_j|)^2} \right) \|\mu_i - \mu_j\|^2 \end{aligned}$$

De forma semejante se puede calcular  $\sum_{i \in C_j} \|x_i - \mu_{ij}\|^2$ :

$$\begin{aligned} \sum_{i \in C_j} \|x_i - \mu_{ij}\|^2 &= \sum_{i \in C_j} \left\| x_i - \left( \mu_j - \frac{|C_i|}{|C_i| + |C_j|} (\mu_i - \mu_j) \right) \right\|^2 \\ &= \sum_{i \in C_j} \left\| (x_i - \mu_j) + \frac{|C_i|}{|C_i| + |C_j|} (\mu_i - \mu_j) \right\|^2 \\ &= \sum_{i \in C_j} \|x_i - \mu_j\|^2 + 2 \sum_{i \in C_j} (x_i - \mu_j) \left( \frac{|C_i|}{|C_i| + |C_j|} \right) (\mu_i - \mu_j) + \sum_{i \in C_j} \left( \frac{|C_i|}{|C_i| + |C_j|} \right) \|\mu_i - \mu_j\|^2 \\ &= \sum_{i \in C_j} \|x_i - \mu_j\|^2 + |C_j| \left( \frac{|C_i|^2}{(|C_i| + |C_j|)^2} \right) \|\mu_j - \mu_j\|^2 \end{aligned}$$

Entonces  $SSE_{ij}$  puede ser escrito de la siguiente manera:

$$\begin{aligned}
SSE_{ij} &= \sum_{x \in C_i} \|x_i - \mu_{ij}\|^2 \\
&= \sum_{i \in C_i} \|x_i - \mu_{ij}\|^2 + \sum_{i \in C_j} \|x_i - \mu_{ij}\|^2 \\
&= \sum_{i \in C_i} \|x_i - \mu_i\|^2 + \sum_{i \in C_j} \|x_i - \mu_j\|^2 + \frac{|C_j||C_i|^2 + |C_j|^2|C_i|}{(|C_i| + |C_j|)^2} \|\mu_i - \mu_j\|^2 \\
&= SSE_i + SSE_j + \frac{|C_j||C_i|}{|C_i| + |C_j|} \|\mu_i - \mu_j\|^2
\end{aligned}$$

por lo tanto,  $I_{ij}$  es igual a:

$$\begin{aligned}
I_{ij} &= SSE_{ij} - (SSE_i + SSE_j) \\
&= SSE_{ij} - SSE_i - SSE_j \\
&= SSE_i + SSE_j + \frac{|C_j||C_i|}{|C_i| + |C_j|} \|\mu_i - \mu_j\|^2 - SSE_i - SSE_j \\
I_{ij} &= \frac{|C_j||C_i|}{|C_i| + |C_j|} \|\mu_i - \mu_j\|^2
\end{aligned}$$